



Clase 7:

Ajustes de datos

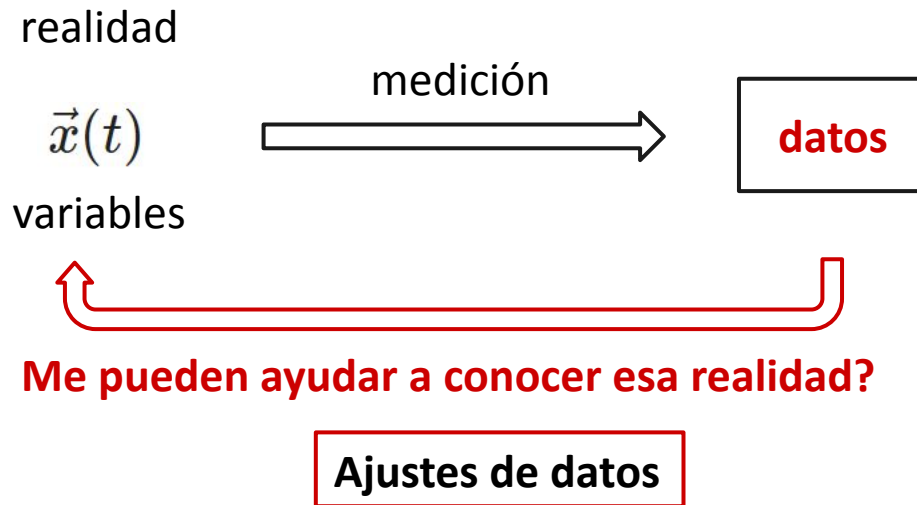


Ajustes de datos

- Motivación en el marco de la materia
- Modelado
- Ajustes de datos
 - Regresión
 - Interpolación
- Vamos a hacer en el Colab
- Bibliografía

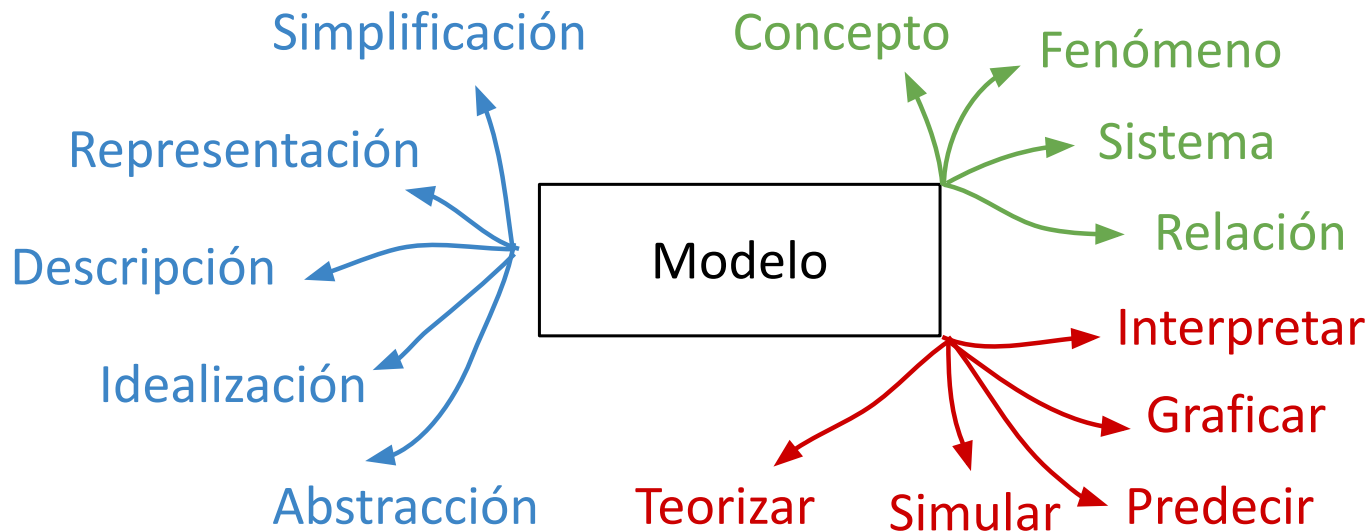
Motivación en el marco de la materia

- Supongo que la realidad se representa con variables continuas




Modelado

Cómo definirían qué es un modelo?



Modelado

Data driven vs hypothesis driven



- Enfoques distintos
 - Capacidad predictiva
 - Interpretabilidad
- Tienen parte del otro enfoque
 - Hipótesis desde una observación
 - Modelos data-driven específicos según la tarea
- Pueden interactuar

Modelado



Qué le pido a un modelo?

1. Que ajuste bien a los datos
2. Que permita hacer predicciones
3. Que sea interpretable




Modelado estadístico clásico; bondad de ajuste (1)


Modelos predictivos; separación en entrenamiento (1) y testeo (2) para evaluar sobreajuste (generalización)

Principio de parsimonia; usar los modelos más simples dentro de lo útil, porque no sobreajustan (2) y son interpretables (3)


Regresión



Regresión lineal





Regresión no lineal (polinomio, etc)



Propongo un **modelo** a partir del cual hay una **relación entre variables** (**variables independientes y variables dependientes**)

Estimo los **parámetros** que hacen que el **modelo** se **ajuste** a mis **datos**

Regresión lineal




En datos reales tengo una componente aleatoria de ruido (puede ser natural)

Necesito resolver el sistema sobredeterminado

Voy a ajustar con una recta que no pasa exactamente por todos los puntos

Regresión lineal



$$J(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \underbrace{(y^{(i)} - \hat{y}^{(i)})^2}_{\text{error}}$$

└─ Función costo

Variable
dependiente

Parámetros

Variable
independiente

$$Y_i = \beta_0 + \beta_1 X_i$$

Ajuste del modelo (estimación)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$

Error cuadrático medio

Ajustar un modelo es básicamente resolver un problema de **optimización** que consiste en encontrar los **parámetros que minimizan una función costo**

Cuadrados mínimos (OLS)

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - t_i)^2 \quad \longleftrightarrow \quad RSS = \sum_{i=1}^n e^{(i)2} = \sum_{i=1}^n (y^{(i)} - \hat{\beta}_0 - \hat{\beta}_1 \cdot x_1^{(i)})^2$$

Es posible **minimizar esta suma** de distancias **analíticamente** de modo de hallar los **mejores estimadores** para los parámetros **β_0 y β_1**

Derivando e igualando a cero las derivadas parciales respecto de los parámetros, se buscan los mínimos de la función suma de **distancias al cuadrado**

$$\frac{\delta RSS}{\delta \hat{\beta}_0} = 0 \quad \frac{\delta RSS}{\delta \hat{\beta}_1} = 0$$

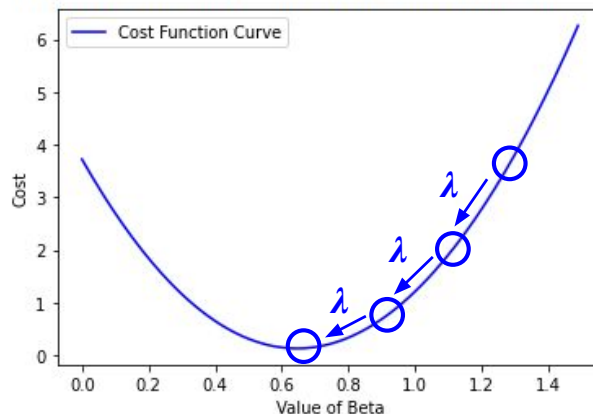

**Estimadores de
parámetros**

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Tienen una
distribución de
probabilidades

Descenso por el gradiente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$



Error cuadrático medio

$$J(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \underbrace{(y^{(i)} - \hat{y}^{(i)})^2}_{\text{error}}$$

↳ **Función costo**


Gradiente: $\frac{\partial J(\hat{\beta})}{\partial \hat{\beta}}$

Uno de los métodos de minimización de la función costo, y el más usado, es el de **descenso por el gradiente**, con un paso llamado **learning rate** (lambda)


Descenso por el gradiente

$$\theta_j \leftarrow \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

Learning rate (alpha; lambda): Factor que aporta al paso en el que me muevo cada iteración en la dirección que desciende el gradiente



Tardo en encontrar el mínimo, a riesgo de cortar la iteración antes de encontrar un valor suficientemente óptimo




Pasos muy grandes me pueden hacer oscilar alrededor del mínimo a riesgo de nunca encontrarlo

Descenso por el gradiente

$$\theta_j \leftarrow \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

Amplitud del gradiente: Me dice cuánto voy a reducir el costo al moverme un paso en cada dirección que indica el gradiente



El tamaño del paso también está determinado por la **amplitud del gradiente** evaluado en los valores de parámetros antes de moverme.

Cuando me acerco al mínimo, la derivada se hace más chica, y el paso también, aún cuando el learning rate esté fijo.

No es necesario ir reduciendo el alpha siempre, aunque a veces puede servir.

Interpolación




- Ajustamos para que el modelo pase por todos los N puntos (no ruido)
- Lo más estándar es usar polinomios de grado $N-1$
- Métodos numéricos clásicos: Lagrange, Newton, Vandermonde
- Puede presentar oscilaciones para N grande (fenómeno de Runge)
- Soluciones pueden ser Chebyshev o interpolación por tramos (splines)
- De gran utilidad para visualización, porque encuentro valores intermedios entre puntos, con curvas suaves, imponiendo la restricción de que la curva pase exactamente por esos puntos
- También para mejorar estimaciones de las derivadas, de las raíces, etc

Vamos a hacer en el Colab




- Regresión
 - Población
 - Oscilador amortiguado (video)
- Filtro Savitzky-Golay
 - Derivada numérica suave
- Interpolación
 - Herramienta para encontrar raíces, visualizar


Bibliografía recomendada



Kutz 2013



Brunton & Kutz 2019



James et al 2017

